

Wearable Stress Detection con WESAD

Report dettagliato per preparazione della presentazione e studio orale. Il progetto sviluppa una pipeline completa di machine learning per classificare finestre fisiologiche come stress o non-stress usando segnali wearable e chest del dataset WESAD.

Dataset WESAD	Task Stress vs non-stress	Validazione LOSO	Campioni 1069 finestre
-------------------------	-------------------------------------	----------------------------	----------------------------------

File principali generati: `data_features/*.csv`, `results/*_summary.txt`, report HTML dei singoli segnali e questo documento complessivo.

1. Sintesi Esecutiva

L'obiettivo del progetto e' costruire una pipeline capace di riconoscere stati psicofisiologici, in particolare lo stress, partendo da segnali fisiologici acquisiti con sensori indossabili o medicali. Il dataset scelto e' WESAD, un dataset da letteratura molto usato per stress detection, che contiene segnali da wrist device e da sensori chest.

Il task finale implementato e' una classificazione binaria: finestre **stress** contro finestre **non-stress**. Le label originali WESAD usate sono: baseline, stress e amusement. Baseline e amusement vengono mappate nella classe non-stress, mentre stress viene mappato nella classe stress.

Risultato piu' forte: il canale RESP chest con Random Forest e 28 feature non ridondanti ottiene accuracy aggregata **90.18%** e F1 aggregato sulla classe stress **83.41%**, valutato con Leave-One-Subject-Out.

Il progetto non si limita a una singola prova: sono stati implementati piu' segnali, piu' modelli, feature engineering, normalizzazione rispetto alla baseline personale, riduzione delle feature e analisi per soggetto. Questo risponde bene alle linee guida del progetto d'esame, che chiedono non solo implementazione tecnica, ma anche analisi metodologica e confronto critico.

2. Coerenza Con Le Linee Guida Dell'Esame

Richiesta delle linee guida	Come e' stata soddisfatta nel progetto
Selezione dataset da letteratura	Scelto WESAD, dataset noto per stress e affect detection con sensori fisiologici.
Selezione task di classificazione	Task binario: stress (1) vs non-stress (0).
Preprocessing e filtraggio	Segmentazione uniforme a 60 s, step 30 s, soglia di purezza label 0.70, filtri specifici per segnale.
Feature extraction	Feature statistiche, fisiologiche, HR/HRV, EDA tonica/fasica, EMG spettrale, RESP respiratoria.
Classificatori e confronto approcci	kNN per BVP/EDA, Random Forest per ECG/EMG/RESP, tuning e varianti con feature ridotte.
Validazione cruciale per dati fisiologici	Leave-One-Subject-Out, cioe' ogni soggetto viene testato come persona mai vista.
Normalizzazione del segnale/features	StandardScaler solo nei fold kNN; baseline normalization per EDA ed ECG; niente scaling per Random Forest.
Performance non solo accuracy	Precision, recall, F1, confusion matrix, feature importance e performance per soggetto.
Benchmark e letteratura	Replica indicativa BVP+kNN e confronto con valori del paper; estensioni personali su altri segnali.

3. Dataset WESAD E Task Di Classificazione

WESAD contiene segnali fisiologici acquisiti durante condizioni sperimentali diverse. Nel nostro progetto usiamo 15 soggetti validi: da S2 a S17, escludendo S1 e S12. Tutti i segnali vengono ricondotti alla stessa struttura di finestre temporali, in modo che i risultati dei vari canali siano confrontabili.

3.1 Label usate

Label WESAD originale	Significato	Label binaria nel progetto
1	Baseline / riposo	0 non-stress
2	Stress	1 stress
3	Amusement / emozione positiva	0 non-stress

Questo punto va spiegato bene all'orale: il task non e' solo stress vs baseline, ma stress vs non-stress. La classe non-stress include sia baseline sia amusement.

3.2 Segmentazione

Tutti i segnali vengono segmentati in finestre da 60 secondi, con passo da 30 secondi. Per ogni finestra viene calcolata la label maggioritaria. La finestra viene tenuta solo se la label maggioritaria ha purezza almeno 0.70. Questo evita di allenare il modello su finestre ambigue, ad esempio finestre che attraversano transizioni tra fasi.

Parametro	Valore	Motivo
Window size	60 s	Abbastanza lunga per stimare feature fisiologiche stabili.
Step	30 s	Overlap del 50%, aumenta campioni senza cambiare troppo il contenuto.
Purezza label	0.70	Riduce finestre miste o ambigue.
Campioni finali	1069	Stesso numero di finestre per i segnali principali.
Distribuzione classi	748 non-stress, 321 stress	Dataset sbilanciato verso non-stress.

4. Pipeline Generale

La pipeline e' stata progettata in modo modulare: per ogni segnale esiste uno script di estrazione feature, uno script di validazione del CSV e uno script di training/validazione del modello. Questo rende il progetto controllabile e riproducibile.

1. Caricamento dei pickle WESAD.
2. Selezione del segnale da analizzare.
3. Allineamento con le label del dataset.

4. Segmentazione temporale in finestre.
5. Filtraggio del segnale quando necessario.
6. Estrazione feature.
7. Validazione del CSV: colonne, NaN, valori infiniti, label, soggetti, allineamento finestre.
8. Training del modello.
9. Validazione Leave-One-Subject-Out.
10. Analisi di metriche, confusion matrix, soggetti difficili e feature importance.

Regola anti-leakage: colonne come `subject`, `start_sec`, `end_sec`, `original_label`, `label` e `label_purity` non vengono usate come feature. Sono metadata o target.

5. Strategia Di Validazione: Leave-One-Subject-Out

Nei dati fisiologici il problema piu' importante e' la variabilita' tra persone. Una validazione casuale riga-per-riga sarebbe troppo ottimistica, perche' finestre dello stesso soggetto potrebbero finire sia nel training sia nel test. In quel caso il modello imparerebbe anche caratteristiche personali del soggetto, non solo lo stress.

Per questo e' stata usata la validazione **Leave-One-Subject-Out**. A ogni fold si lascia fuori un soggetto intero come test set e si allena il modello sui restanti soggetti. Se ci sono 15 soggetti, ci sono 15 fold.

Metodo	Come funziona	Perche' e' adatto
LOSO	Training su 14 soggetti, test sul soggetto escluso.	Simula l'applicazione reale su una persona nuova.
Aggregazione metriche	Si raccolgono tutte le predizioni dei fold e si calcolano accuracy, precision, recall, F1.	Da una visione globale su tutte le finestre testate.
Analisi per soggetto	Ogni fold produce metriche sul soggetto lasciato fuori.	Permette di vedere soggetti problematici.

Questa scelta e' metodologicamente forte e va sottolineata nella presentazione: il modello non viene testato su finestre di soggetti gia' visti, ma su soggetti completamente esclusi dal training.

6. Segnali Analizzati

Segnale	Posizione	Frequenza	Modello principale	Ruolo nel progetto
BVP	Wrist	64 Hz	kNN	Baseline vicina al paper e confronto con letteratura.
EDA	Wrist	4 Hz	kNN	Segnale forte per stress, migliorato con baseline normalization.
ECG	Chest	700 Hz	Random Forest	Feature cardiache e HRV; grande beneficio dalla normalizzazione personale.
EMG	Chest	700 Hz	Random Forest	Segnale piu' debole, utile come confronto negativo e analisi critica.
RESP	Chest	700 Hz	Random Forest	Risultato finale piu' forte, con feature ridotte non ridondanti.

7. Feature Extraction Per Segnale

7.1 BVP wrist

BVP misura variazioni di volume sanguigno periferico. Dal BVP sono state estratte feature statistiche e fisiologiche: media, deviazione standard, min, max, range, mediana, IQR, RMS, energia, skewness, kurtosis, numero di picchi, intervalli tra battiti stimati, heart rate e indici HRV semplici.

BVP e' importante perche' permette una replica indicativa della pipeline riportata nel paper WESAD con kNN. Il nostro risultato BVP+kNN e' vicino all'accuracy del riferimento, anche se il F1 differisce.

7.2 EDA wrist

EDA misura l'attivita' elettrodermica, fortemente legata al sistema nervoso simpatico. Sono state estratte feature statistiche, slope, derivate, componente tonica, componente fasica e SCR rilevate tramite picchi. EDA e' uno dei segnali piu' rilevanti per stress detection.

Per EDA sono state provate feature complete, feature ridotte e normalizzazione rispetto alla baseline personale. La versione migliore usa feature ridotte piu' delta e z-score rispetto alla baseline del soggetto.

7.3 ECG chest

ECG permette di estrarre informazioni cardiache piu' precise rispetto al BVP. Il segnale viene filtrato, poi si stimano R-peak, intervalli RR, heart rate e feature HRV come RMSSD, SDNN, pNN50 e CVNN. Sono state testate feature assolute e feature normalizzate rispetto alla baseline personale.

La normalizzazione personale e' stata molto importante: il modello assoluto ECG era discreto, ma la versione baseline z-score ha migliorato drasticamente F1 e accuracy.

7.4 EMG chest

EMG misura attivita' muscolare. Sono state estratte feature statistiche, ampiezza rettificata, IEMG, MAV, waveform length, zero crossing, slope sign changes, Willison amplitude, feature Hjorth e feature spettrali Welch.

EMG si e' rivelato meno forte degli altri segnali. Questo pero' e' utile nel progetto: mostra che non tutti i canali sono ugualmente informativi per lo stress e giustifica l'analisi comparativa.

7.5 RESP chest

RESP misura la respirazione toracica. Il segnale viene filtrato tra 0.05 e 2 Hz, poi vengono estratte feature su ampiezza, variabilita', derivate, picchi/trough respiratori, breath rate, intervalli respiratori e spettro Welch. La prima versione aveva 52 feature candidate, poi ridotte a 28 per eliminare ridondanze.

RESP e' risultato il canale piu' forte nella versione finale: poche feature interpretabili e ottima performance in LOSO.

8. Modelli E Normalizzazione

8.1 kNN

kNN classifica una finestra guardando i campioni piu' vicini nello spazio delle feature. Per questo e' molto sensibile alla scala delle feature: una feature con valori grandi puo' dominare la distanza. Nei modelli kNN e' stato quindi usato `StandardScaler`, fittato solo sul training fold per evitare leakage.

La configurazione principale e' `KNeighborsClassifier(n_neighbors=9, weights="distance")`. Il peso distance da piu' importanza ai vicini piu' simili.

8.2 Random Forest

Random Forest combina molti alberi decisionali. Ogni albero impara split sulle feature e la previsione finale e' ottenuta per voto. E' adatta a feature non lineari e non richiede scaling, perche' gli alberi non usano distanze euclidee.

La configurazione usata per i modelli RF principali e': `n_estimators=300`, `min_samples_leaf=2`, `class_weight="balanced"`, `random_state=42`. Il parametro `class_weight="balanced"` aiuta perche' le classi sono sbilanciate: ci sono piu' finestre non-stress che stress.

8.3 Baseline normalization

Per EDA ed ECG e' stata testata la normalizzazione rispetto alla baseline personale. Per ogni soggetto si usano solo finestre con `original_label=1` per calcolare media e deviazione standard di alcune feature. Poi si costruiscono:

- `baseline_delta`: valore finestra meno media baseline personale.
- `baseline_zscore`: delta diviso deviazione standard baseline personale.

Questa scelta e' metodologicamente difendibile se si assume una fase iniziale di calibrazione a riposo per il soggetto. Non vengono usate finestre stress per costruire la baseline.

9. Risultati Principali

Segnale / modello	Feature	Accuracy	Precision stress	Recall stress	F1 stress	Confusion matrix
BVP wrist + kNN LOSO	25	82.79%	72.03%	69.78%	70.89%	TN=661, FP=87, FN=97, TP=224
EDA wrist + kNN baseline norm	36	89.52%	88.28%	75.08%	81.14%	TN=716, FP=32, FN=80, TP=241
ECG chest + RF baseline z-score	12	86.44%	83.08%	68.85%	75.30%	TN=703, FP=45, FN=100, TP=221
EMG chest + RF top15	15	69.78%	49.70%	51.09%	50.38%	TN=582, FP=166, FN=157, TP=164
RESP chest + RF ridotta	28	90.18%	84.62%	82.24%	83.41%	TN=700, FP=48, FN=57, TP=264

Il ranking finale mostra che RESP e EDA sono i canali piu' efficaci in questa pipeline. ECG diventa buono quando viene normalizzato sulla baseline personale. BVP fornisce una baseline solida e vicina al paper. EMG e' meno efficace, ma utile per dimostrare che la scelta del segnale conta.

10. Focus Sul Miglior Risultato: RESP Chest

Il canale RESP e' stato l'ultimo aggiunto ed e' diventato il risultato piu' forte. La prima estrazione produceva 52 feature candidate. Dopo un controllo sulla ridondanza, sono state mantenute 28 feature effettive. Il CSV finale ha 36 colonne totali: 28 feature e 8 metadata/label.

10.1 Perche' eliminare feature ridondanti

Troppe feature non sono sempre un vantaggio. Alcune colonne erano deterministiche o quasi duplicate: ad esempio conteggi e rate su finestre sempre da 60 s, oppure frequenza dominante in Hz e in bpm. Rimuoverle rende il modello piu' leggero e piu' spiegabile.

Versione RESP	N feature	Colonne CSV	Accuracy	Precision	Recall	F1
Prima versione	52	60	89.71%	83.71%	81.62%	82.65%
Versione finale ridotta	28	36	90.18%	84.62%	82.24%	83.41%

La riduzione ha migliorato leggermente tutte le metriche principali. Questo e' un buon argomento metodologico: il modello finale non e' solo piu' accurato, ma anche piu' semplice.

10.2 Feature RESP piu' importanti

#	Feature	Importanza media	Interpretazione
1	resp_bandpower_0_75_2_00	0.1686	Potenza nella banda respiratoria alta.
2	resp_relative_power_0_75_2_00	0.1233	Quota relativa di potenza ad alta frequenza.
3	resp_interval_cv	0.1005	Variabilita' normalizzata degli intervalli respiratori.
4	resp_second_derivative_std	0.0984	Irregolarita' e accelerazioni del segnale.
5	resp_breath_rate_std	0.0723	Variabilita' del ritmo respiratorio.
6	resp_interval_rmssd	0.0660	Variazione ciclo-ciclo degli intervalli.
7	resp_interval_sdn	0.0432	Variabilita' globale degli intervalli.
8	resp_breath_rate_range	0.0415	Differenza tra breath rate massimo e minimo.

Il modello non si basa solo sul breath rate medio. Le feature piu' importanti catturano variabilita', irregolarita' e componenti ad alta frequenza. Questo e' coerente con l'idea che lo stress possa alterare stabilita' e pattern respiratorio piu' che semplicemente aumentare la frequenza media.

11. Analisi Critica Dei Risultati

11.1 Accuracy non basta

Il dataset e' sbilanciato: 748 finestre non-stress contro 321 finestre stress. Un modello potrebbe ottenere accuracy alta predicendo spesso non-stress. Per questo sono state sempre riportate precision, recall e F1 sulla classe stress.

- **Precision stress:** tra le finestre predette stress, quante sono davvero stress.
- **Recall stress:** tra le finestre davvero stress, quante vengono riconosciute.
- **F1 stress:** media armonica tra precision e recall, utile quando le classi sono sbilanciate.

11.2 Falsi positivi e falsi negativi

Nel modello RESP finale ci sono 48 falsi positivi e 57 falsi negativi. I falsi negativi sono finestre stress classificate come non-stress. In applicazioni reali di stress detection, i falsi negativi sono spesso piu' critici perche' rappresentano stress non rilevato.

Per questo il recall stress e' importante. RESP raggiunge recall 82.24%, migliore di BVP, EDA baseline norm, ECG baseline norm ed EMG top15 nella nostra comparazione finale.

11.3 Soggetti difficili

L'analisi per soggetto mostra che alcuni soggetti sono piu' difficili. Nel modello RESP i soggetti sotto soglia sono S4 e S6. In particolare S6 ha molti falsi negativi. Questo indica che la risposta fisiologica allo stress puo' essere molto individuale.

Questa osservazione rafforza la scelta di LOSO e delle strategie di baseline normalization: nei dati fisiologici la variabilita' individuale e' una parte centrale del problema.

12. Confronto Con La Letteratura E Replicabilita'

Le linee guida chiedono di consultare la letteratura e tentare una replica della pipeline del paper scelto. Nel progetto, BVP+kNN e' stato usato come punto di partenza vicino al benchmark WESAD. La replica e' indicativa, perche' non tutti i dettagli della pipeline originale sono necessariamente identici: filtraggio, feature esatte, gestione transizioni, finestre e validazione possono cambiare.

Confronto BVP+kNN	Accuracy	F1	Nota
Riferimento paper WESAD indicativo	circa 82.06%	circa 78.94%	Valori usati come benchmark di massima.
Nostra pipeline BVP+kNN	82.79%	70.89%	Accuracy molto vicina; F1 inferiore, probabilmente per differenze di feature/label/validazione.

Dopo questa baseline, il progetto procede con modifiche personali: EDA con feature ridotte e baseline normalization, ECG con z-score personale, EMG con top15, RESP con feature respiratorie ridotte. Questa evoluzione e' coerente con la parte opzionale delle linee guida, che invita a proporre nuove feature o strategie per migliorare o alleggerire il modello.

13. Cosa Dire Nella Presentazione

Il PowerPoint deve essere sintetico, massimo 15 slide. Questo PDF contiene molto piu' dettaglio; in classe conviene raccontare solo il filo logico.

Slide	Contenuto consigliato	Messaggio da dire
1	Titolo e obiettivo	Classificare stress vs non-stress da segnali fisiologici WESAD.
2	Dataset WESAD	Segnali wrist e chest, task binario, soggetti esclusi.
3	Pipeline generale	Segmentazione, filtraggio, feature extraction, validazione CSV, training.
4	Label e finestre	Baseline/amusement = non-stress, stress = stress; finestre 60s/30s.
5	Validazione LOSO	Ogni soggetto e' testato come persona nuova.
6	BVP baseline	Replica indicativa con kNN e confronto con paper.
7	EDA	EDA migliora con baseline normalization.
8	ECG	HRV e z-score personale aumentano molto la performance.
9	EMG	Canale meno forte, utile come confronto critico.
10	RESP	Canale migliore, 28 feature non ridondanti.
11	Tabella risultati	Confronto accuracy, precision, recall, F1.
12	Confusion matrix RESP	Spiegare falsi positivi/falsi negativi e recall stress.
13	Feature importance RESP	Variabilita' respiratoria e potenza alta frequenza sono centrali.
14	Analisi critica	Soggetti difficili, limiti, differenze dalla letteratura.
15	Conclusioni	Pipeline coerente, RESP/EDA migliori, LOSO robusto.

14. Domande Possibili Della Prof E Risposte

Perche' avete usato LOSO invece di train/test casuale?

Perche' i dati fisiologici sono fortemente dipendenti dal soggetto. Un split casuale potrebbe mettere finestre dello stesso soggetto sia in training sia in test, producendo una stima troppo ottimistica. LOSO testa il modello su soggetti mai visti.

Perche' baseline e amusement sono entrambe non-stress?

Il task scelto e' stress vs non-stress. Baseline rappresenta riposo, amusement rappresenta uno stato positivo non stressante. Entrambe sono quindi mappate a classe 0. Questa scelta va dichiarata perche' e' diversa da stress vs baseline puro.

Perche' non avete usato solo accuracy?

Perche' il dataset e' sbilanciato: ci sono molte piu' finestre non-stress. Accuracy puo' essere alta anche se il modello riconosce male lo stress. Precision, recall e F1 sulla classe stress sono piu' informative.

Perche' kNN viene scalato e Random Forest no?

kNN usa distanze, quindi la scala delle feature influenza direttamente il modello. Random Forest usa split ad albero, quindi non richiede scaling. Quando abbiamo usato StandardScaler, lo abbiamo fittato solo sul training fold per evitare leakage.

La baseline normalization usa informazioni del test?

Usa solo finestre baseline del soggetto test, non finestre stress. Questo equivale ad assumere una fase di calibrazione a riposo disponibile prima dell'uso del sistema. E' un'assunzione esplicita e fisiologicamente sensata.

Perche' RESP funziona cosi' bene?

Perche' lo stress puo' modificare ritmo, variabilita' e regolarita' della respirazione. Le feature piu' importanti RESP catturano proprio variabilita' degli intervalli, potenza in banda alta e irregolarita' del segnale.

Perche' EMG va peggio?

EMG puo' dipendere molto da postura, movimento e contrazioni muscolari non direttamente legate allo stress. Nel nostro task e con questa pipeline e' meno discriminativo. Il risultato e' comunque utile per il confronto tra sensori.

Perche' avete tolto feature RESP ridondanti?

Per rendere il modello piu' semplice e meno rumoroso. Alcune feature erano duplicati informativi: per esempio conteggio e rate su finestre sempre da 60 secondi. Dopo la riduzione, le metriche sono anche migliorate.

Qual e' il contributo personale rispetto al paper?

Oltre alla baseline BVP+kNN, abbiamo implementato pipeline multi-segnale, feature engineering specifico, baseline normalization per EDA/ECG, riduzione feature per EMG/RESP e analisi comparativa con LOSO.

15. Limiti E Sviluppi Futuri

- **Dataset limitato:** 15 soggetti sono utili per un progetto, ma non bastano per conclusioni cliniche generali.
- **Task binario:** abbiamo unito baseline e amusement in non-stress. Un lavoro futuro potrebbe fare classificazione multi-classe.
- **Sensor fusion:** il progetto confronta segnali separati. Una possibile estensione e' combinare RESP+EDA o RESP+ECG.
- **Tuning limitato:** abbiamo mantenuto modelli interpretabili e poco ottimizzati. Un tuning piu' ampio potrebbe migliorare alcuni segnali.
- **Soggetti difficili:** alcuni soggetti restano problematici, confermando la variabilita' individuale della risposta allo stress.

16. Conclusione

Il progetto e' coerente con le linee guida dell'esame: parte da un dataset da letteratura, implementa preprocessing, filtraggio, feature extraction, classificatori, validazione subject-independent e analisi delle metriche. Inoltre contiene elementi sperimentali personali, come normalizzazione rispetto alla baseline, riduzione feature e confronto tra segnali.

Il risultato finale piu' convincente e' RESP chest + Random Forest con 28 feature non ridondanti: accuracy 90.18%, precision stress 84.62%, recall stress 82.24% e F1 stress 83.41%. EDA baseline-normalized e' il secondo risultato piu' forte, mentre ECG dimostra chiaramente l'importanza della normalizzazione personale.

Il messaggio finale da portare in classe e': **nei dati fisiologici non basta scegliere un classificatore; contano moltissimo validazione per soggetto, normalizzazione individuale, scelta del segnale e feature interpretabili.**